OpenWorkBuddy 项目状态简报

求职用途 · AI 应用工程师 · 材料基准日 2026-10-26

一、项目定位

面向个人的工作助手，本机优先、小规模持续迭代，保留 Python + React 小内核，调研、文档与办公自动化优先 [S2 p1]。M0–M3 已落地附件、文档读写、来源编号、飞书连接器、独立浏览器、定时任务、历史检索与备份 [S2 p1]。二轮复审的结论是：这些功能"已经实现，不等于验收条件已经满足"，下一阶段应收敛到可靠性修订与完整工作流试用，暂缓 Code Mode、多代理和新增平台 [S2 p1]。同一轮以隔离探针发现 11 组缺陷或契约缺口，集中在模块交接处（请求登记与接收、任务认领与投递、审批预览与载荷、运行失败与业务结果、备份与恢复路径）[S2 p1]。

二、三个数量阶段，不能混用

阶段	全量回归	说明
复审基线	221 项全通过	复审时点基线，`pytest -q` 27.42 s [S2 p2]；表格记为 25.247 s [S1]
R-B	340 项	新增 39 项 R-B 回归 [S3]
R-C	372 项	新增 32 项 R-C 后端回归，另 5 条 Chromium E2E 通过 [S3]

三个阶段均为 0 失败、0 跳过 [S1]。差值可以这样核对：221 → 249（R-A 之前，材料未说明来源的 +28）→ 301（R-A 新增 52）→ 340（+39）→ 372（+32）[S3]。R-C 保留了初次全量失败记录及上下文预留修订 [S3]。因此对外只报"基线 221、当前 372"，不把 221 说成当前数字，也不省略中间阶段。

三、测试增量与开发集 token 是两件事

372 是回归用例条数，不是任务数，也不是成功率。开发集是另一个尺度：12 个任务，初始自动检查通过 5/12，有审计记录的 grader 修订后为 9/12，现状为 9 次待人工评阅、3 次保留失败 [S3]。该轮输入 619,064、输出 27,327 token，输入中已含 529,664 缓存读取 token，费用未知 [S3]。由于材料没有给出可直接换算的口径，简报不做"每条测试多少 token"之类的推算。

四、尚未完成的部分

费用未知，需按实际账单核算 [S3]；开发集 6 个任务仍需独立人工评阅，Word"能打开"不等于视觉或事实验收 [S3]；R-B 未做真实用户数据恢复与收费模型测试 [S3]；R-C 使用合成资料、本地模拟模型与临时目录，新增真实模型/搜索调用和真实办公写入均为 0，托管 CI 未验证 [S3]；R-D 的 6 类任务各 2 次共 12 个槽位均未执行，正式评测（含留出集冻结）尚未开始 [S3]。

五、可以说与不能说

可以说：独立完成从 M0 到 R-C 的迭代，把回归覆盖从 221 扩到 372 条并保持全绿，把评测做成可冻结、可审计的流程 [S1][S3]。不能说：业务成功率 9/12、效率超过同类产品；复审明确当前缺少真实任务样本，无法支撑此类结论 [S2 p1]。

参考文献

- [S1] validation-history.csv · file:///Users/Zhuanz/Documents/GitHub/OpenWorkBuddy/eval-runs/rd-project-2026-10-26-r2/U1-1/workspace/validation-history.csv · 访问 2026-10-26T08:40:38Z · inspected · lines 1-4 (line caps 2000) · SHA256 45be383f4c6d29286e33de4a045e37f0d3845b30ea7b24eb229c49a3d02deaf3
- [S3] current-status.docx · file:///Users/Zhuanz/Documents/GitHub/OpenWorkBuddy/eval-runs/rd-project-2026-10-26-r2/U1-1/workspace/current-status.docx · 访问 2026-10-26T08:40:38Z · inspected · document 1-1; output lines 1-2000 · SHA256 e5ceb42feb388b6f57c7a4f361d6ac5510764a7893aca4c90d87cd9bf9ebff4c

来源状态仅表示获取、提取或上下文读取进度；不代表事实或计算已经核验。