# OpenWorkBuddy 当前实施进度原文节选

项目真实资料的原文节选，用于本地读取与简报试用。标题为整理标识，正文按冻结来源保留。

**docs/design/2026-10-25-resume-implementation-status.md**

开发试跑发现**的**问题

这些是开发集的调试证据，不从分母删除，也不当成正式模型能力比较：

1. Word 数字检查只匹配 `2160`，把正确的 `2,160` 判错。已改为数值解析，保留初始判定并离线重评分。

2. 来源冲突题公开请求没有列文件名，而限定工具不提供目录枚举。新版已注入文件清单；原两次预算失败保留。

3. 初版系统提示包含物理工作目录，路径带 A/B 标签。新版整轮冻结同一份提示、使用随机无标签物理目录，有子进程回归。

4. 初版只允许 `root/*`，遗漏工作目录本身，产生一次严格 scope 检查失败。新版已补上 root，原失败标注为 harness 问题且未删除。

5. 草稿题只写“updated.md”，grader 误设为必须在根目录。校准允许输入草稿同目录的合法输出；新版任务明确全路径。

6. 6 个开发任务仍需独立人工评阅。Word 的可打开检查不等于视觉或事实验收；v2 未追加收费试跑。

首轮初始自动检查通过 5/12；有审计记录的 grader 修订后为 9/12。当前 9 次等待人工评阅、3 次保留失败，

不输出任务完成率或 pass^3。输入 619,064、输出 27,327 token；输入已包含 529,664 缓存读取 token，费用未知。

全量测试及静态检查见 [测试证据](../research/2026-10-25-eval-preparation-tests.xml)。

上一阶段验证：**249 项测试通过，0 失败、0 跳过（39.68 秒）**；`ruff check src tests evals`、

`git diff --check` 与 v2 数据/源码 freeze 校验通过。回归包括真实子进程超时 SIGKILL、

残留 started 调用的未知 usage、调用上限、评分修订不重跑模型、跨协议异常结束与恢复用量累计。

**尚未**闭环**的二**轮问题

R-A 本地实现已完成：冻结飞书载荷、hook 后固定约束、规范 CLI 参数、浏览器参数级权限、

受控截图输出和逐子文件授权。新增 52 项回归，全量 **301 项通过，0 失败、0 跳过（65.64 秒）**。

本机官方 CLI 仅做 dry-run；隔离 Playwright 仅做空白页导航/截图。未新增收费模型调用或真实飞书外发。

unknown 仍需操作人核验，不自动解锁；浏览器脚本和本地文件上传未开放。

R-B 已实现事务接收、调度补投、状态/证据优先裁定、离线备份与异地重定位。

新增 39 项 R-B 回归；全量 340 项通过，0 失败、0 跳过（64.51 秒），含 11 个子进程硬退出场景。

原 home 移走后验证历史、附件、旧版本、检索、定时补投和继续执行；飞书未知操作隔离与回执恢复仍有效。

CLI 临时目录备份/恢复和前端构建通过；备份需停止服务/Agent 写者，外部项目文件不在归档内。

上述 R-B 未进行真实用户数据恢复或收费模型测试。

R-C 已实现来源状态、内容版本/快照、实际上下文片段记录、导出文献表和四层校验；

检索默认当前项目/本会话，跨项目需主动启用，提供排除索引与 read_record。

单个后台解析任务有界增量索引，rollback/坏附件/范围变更有回归。

会话预算覆盖模型/工具调用和墙钟时间，恢复沿用冻结上限，诊断显示失败与未知费用。

新增 32 项 R-C 后端回归，全量 **372 项通过，0 失败、0 跳过（60.98 秒）**；

**5 条 Chromium 浏览器 E2E 通过（5.22 秒，0 重试）**，覆盖附件、审批、断线恢复、下载与任务状态。

ruff、前端构建、diff 检查通过；保留初次全量失败及上下文预留修订，详见 [验证清单](../research/2026-10-26-rc-validation.json)。

本次使用合成资料、本地模拟模型和临时数据目录，新增真实模型/搜索调用与真实办公写入均为 0；

Word/PDF 的数字、版式与事实人工验收仍未评估，托管 CI 尚未验证。

下一阶段为 R-D 的 6 类真实任务各 2 次；[试用卡](../research/2026-10-26-rd-trial-protocol.md) 已准备，12 个槽位均未执行。

开发集独立人工评阅仍待完成，再冻结留出集和正式试验。

本次产品源码已变化，原 v2 freeze 保留作历史证据；后续模型运行必须重新冻结到新文件和新 run 目录。

正式试验的预算需要依据开发集完整结果重新估算；本次授权只执行这轮 12 次开发 trial，未追加收费重跑。