OpenWorkBuddy 二轮复审原文节选

docs/design/2026-10-24-personal-assistant-re-review.md

1. 本轮结论

这轮改进显著扩大了可用能力，也修复了上次多个具体问题。下一阶段应收敛到“可靠性修订 + 完整工作流试用”，暂缓 Code Mode、多代理和新增平台。

项目已有附件、文档读写、来源编号、版本化产物、飞书连接器、独立浏览器、定时任务、历史检索和备份。它从以聊天和编程为主的 harness，向个人工作助手前进了一大步。

但 M0–M3 的功能已经实现，不等于这些里程碑的全部验收条件已经满足。本轮 **221 项现有测试全部通过**，同时通过隔离探针观察到 **11 组缺陷或契约缺口**。主要集中在模块交接处：请求登记与实际接收、任务认领与投递、审批预览与最终载荷、运行失败与业务结果、备份文件与实际恢复路径。

用户本轮确认“还没有充分使用”。因此现在缺少真实任务样本和持续使用数据，无法有依据地判断哪个高级功能最值得做，也不能声称整体效率超过 pi、OpenCode 或 DeepSeek Harness。

本次沿用的需求

- 综合个人工作助手，调研、文档、办公自动化优先，兼顾编程。

- 自己使用、本机优先、小规模持续迭代，继续保留 Python + React 小内核。

- 本地文件、浏览器、飞书为首批集成。

- 可以定时整理和准备草稿；发送、发布、删除前确认。

- 实现教程还记录了每周调研模板、合并补跑、macOS 通知、只索引助手记录的选择。本轮不扩大到任意文件夹扫描，也不替用户修改账户授权。

用户本轮进一步确认：**历史检索默认当前项目优先，明确需要时才跨项目检索。** 这是新方案的确定需求；当前代码的全局检索行为尚未修改。

2. 实际审查范围与验证结果

2.1 改动概况

| 提交 | 内容 | 本轮判断 |

|---|---|---|

| `68fb259` | M0：持久输入、请求去重、结束状态检查、锁、SSE、CI | 原有具体故障大多得到针对性修复；跨操作事务和其它协议仍有缺口 |

| `bd76f46` | M1：附件、Office/PDF 阅读、搜索、文档和交付物 | 有了明显的产品价值；来源校验和交付质量仍需分层 |

| `222f15e` | M2：飞书、Playwright MCP 浏览器 | 后端选择合理；不能仅按工具名或 argv 字符串判断副作用 |

| `66dc15b` | M3：调度、全文检索、通知、备份恢复 | 结构保持简洁；调度交接、结果裁定和异地恢复需要补强 |

Git 跟踪源码统计：后端 Python 从 5,434 行增至 8,676 行，测试 Python 从 2,747 行增至 4,003 行，`web/src` 从 3,077 行增至 3,969 行。统计含注释与空行。代码增量仍可控，当前没有重写内核的必要。

2.2 本轮亲自执行

| 验证 | 结果 | 能证明什么 |

|---|---|---|

| `.venv/bin/pytest -q` | **221 passed in 27.42s** | 现有回归范围内通过 |

| `.venv/bin/ruff check` | 通过 | 静态规则通过 |

| `npm --prefix web run build` | TypeScript 检查、Vite 构建通过 | 前端可编译打包，不等于交互 E2E 已通过 |

| 本轮隔离探针 | 11 组结果，见第 4 节 | 覆盖新的中断、授权、恢复和证据边界 |

| 上游协议核验 | Playwright MCP `v0.0.83`、飞书 CLI 固定源码、pflag `v1.0.9` | 核对本项目依赖的实际参数语义 |

探针见 [可复现脚本](../research/2026-10-24-re-review-probes.py)。使用临时项目、合成数据、假模型和假飞书连接器；Anthropic 流测试使用本机 HTTP 服务器和已安装的真实 SDK。没有使用真实 API key，没有发送飞书消息，没有真实打开未授权网站，也没有修改业务源码。

教程 14–16 记录了此前真实模型与组件冒烟测试；本轮将其视为**已有测试记录**，没有重新执行、也不将其等同本轮验收。教程 14 还明确搜索因没有 Tavily key 只做过模拟测试。用户自己的四个未跟踪文件保持原样，不作为程序源码分析。

R10 / P1：引用“检查通过”仍不足以证明阅读过，导出后编号也可能失去出处

位置： `tools/docs.py:77–94`，`artifacts.py:186–198`，`tools/web.py` 的二进制下载分支。

`citation_checks()` 只把 kind=search 标为未阅读全文；kind=file 的下载记录即使尚未解析也会通过已知编号检查。探针创建仅下载的来源记录，生成带 `[S1]` 的 Markdown，全部 artifact checks 为通过，但文件里没有来源 URL。

```json
{"probe":"downloaded_source_and_export","exported_source_url":false,"all_artifact_checks_pass":true}
```

因此不能把“编号存在”“HTTP 抓取完成”“模型读到相关段落”“主张得到支持”合成一个绿色状态。导出文件也需要自带参考文献/脚注，不能只能回到应用里找 `[S1]`。这是报告可信度和可分享性的缺口，不是要求把所有引用正确性都交给另一轮模型裁判。